



AI Generative Text Detection

Merancang Model Deteksi Teks Generatif AI pada Sistem Penilaian Esai Otomatis melalui Fine-Tuning IndoBERT



Oleh: Pitriani



Email: pitripitriani173@gmail.com



Web-Portfolio: <https://ppitria.github.io>



Executive Summary

Proyek ini merupakan **bagian dari penelitian tugas akhir** yang berfokus pada **pengembangan model deteksi teks generatif AI yang diintegrasikan ke dalam sistem penilaian esai otomatis berbasis Natural Language Processing (NLP)**. Tujuan utamanya adalah mendeteksi tingkat kemungkinan suatu jawaban esai dihasilkan oleh model bahasa generatif serta menyesuaikan skor akhir sebagai bentuk penalti terhadap penggunaan teks yang tidak orisinal.

Dataset penelitian terdiri dari kumpulan jawaban esai siswa dan teks hasil generasi AI yang digunakan untuk melakukan **fine-tuning pada model IndoBERT** (indobenchmark/indobert-lite-base-p2).

Sistem penilaian otomatis dikembangkan dengan metode cosine similarity, yang menilai kesesuaian isi jawaban dengan kunci jawaban referensi.


Hasil pengujian menunjukkan bahwa **model deteksi mampu mencapai akurasi 93%**, dengan **performa stabil** dalam membedakan teks AI dan tulisan manusia.

Integrasi kedua sistem ini memungkinkan pemberian skor yang lebih adil, transparan, dan mampu mendeteksi potensi penggunaan AI secara otomatis.

Penelitian ini juga **diimplementasikan ke dalam web berbasis Flask**, dan hasilnya telah **dipublikasikan dalam bentuk artikel ilmiah** sebagai kontribusi terhadap pengembangan sistem penilaian berbasis AI di konteks pendidikan Indonesia.

Data

Kolom	Deskripsi	Contoh Nilai
Text	Teks jawaban esai baik yang ditulis manusia maupun yang dihasilkan AI	Peserta didik dapat memblokir situs tersebut da...
Label	Kategori dari text (AI dan Non-AI)	Non-AI




- Dataset terdiri dari 740 data dengan dua label utama: AI dan Non-AI.
- Label AI merupakan teks yang digenerasi dari 7 model berbeda: ChatGPT, Gemini, Copilot, DeepSeek, Claude, Perplexity, dan Meta AI.
- Label Non-AI merupakan teks asli hasil jawaban siswa dari ujian atau kuis.
- Sebanyak 80 data uji tambahan disiapkan untuk mengevaluasi sistem penilaian yang terintegrasi dengan model deteksi.

Dataset ini menjadi komponen penting dalam tahap fine-tuning, karena kualitas dan keseimbangan antara teks AI dan Non-AI sangat memengaruhi performa akhir model klasifikasi

Modeling

Konfigurasi	Nilai
Epoch	3
Batch Size	8
Learning Rate	0,00003
Weight Decay	0,001



Proses fine-tuning dilakukan pada model IndoBERT menggunakan beberapa penyesuaian konfigurasi hyperparameter untuk mencapai hasil optimal. Nilai konfigurasi terbaik ditunjukkan pada tabel, dengan hasil pelatihan yang stabil seperti terlihat pada grafik Training vs Validation Loss.


Model mencatat nilai akhir training loss sebesar 0.195 dan validation loss sebesar 0.189, yang menunjukkan tidak adanya overfitting dan proses konvergensi berjalan baik. Hasil ini menunjukkan bahwa model telah berhasil beradaptasi dengan baik terhadap karakteristik bahasa Indonesia tanpa mengalami degradasi performa signifikan selama proses fine-tuning.

Evaluation Metrics

Metrik	Label	
	AI	Non-AI
Precision	0,99	0,90
Recall	0,90	0,99
F1-Score	0,94	0,94

Evaluasi dilakukan menggunakan metrik Accuracy, Precision, Recall, dan F1-Score. Model mencapai akurasi 93%, dengan F1-Score tinggi di kedua kelas (AI dan Non-AI), menandakan keseimbangan performa yang baik.

Berdasarkan confusion matrix, model menunjukkan kemampuan deteksi yang konsisten, dari total 148 data, model berhasil mengklasifikasikan 139 data secara benar, terdiri dari 69 data teks AI yang dikenali dengan tepat, dan 70 data teks manusia yang juga terdeteksi dengan benar. Sementara itu, terdapat 9 kesalahan klasifikasi, di mana 8 teks AI diklasifikasikan sebagai teks manusia, dan 1 teks manusia terdeteksi sebagai teks AI.



Detection Models in Automated Grading

No	Similaritas	Similaritas (konversi)	Probabilitas AI (%)	Nilai AKhir
1	0,8756	100	23,68%	76,32
2	0,8789	100	4,37%	95,63
3	0,9346	100	1,07%	98,93

Kolom “Similaritas” menampilkan hasil perhitungan cosine similarity antar teks, sedangkan “Similaritas (Konversi)” adalah hasil konversi nilai tersebut agar mudah digunakan dalam perhitungan skor akhir.

Kolom “Probabilitas AI (%)” menunjukkan hasil dari model deteksi AI, dan “Nilai Akhir” merupakan nilai rekomendasi setelah dilakukan penalti berdasarkan tingkat probabilitas AI.

Misalnya, pada data nomor 1, tingkat probabilitas AI sebesar 23.68% menyebabkan pengurangan skor dari 100 menjadi 76.23 poin. Mekanisme yang sama diterapkan pada data lainnya.

Deployment



Model dan sistem penilaian otomatis diintegrasikan ke dalam web berbasis Flask.

Aplikasi ini didesain secara sederhana, data yang diinputkan berupa jawaban siswa dan kunci jawabannya. Setelah penilaian sekaligus deteksi AI diproses, akan muncul persentase AI terdeteksi, nilai sebelum penyesuaian AI, dan nilai final setelah penyesuaian sebagai nilai rekomendasi penilaian otomatis.

Proses integrasi ini dikembangkan sepenuhnya menggunakan Python (Flask Framework) dengan pendekatan modular design, sehingga sistem dapat dengan mudah diperluas atau dihubungkan dengan modul penilaian lain di masa depan.

Artikel Ilmiah

Hasil penelitian ini telah dituangkan dalam bentuk artikel ilmiah yang membahas arsitektur sistem, hasil eksperimen, serta potensi penerapan di lingkungan pendidikan.

Tautan publikasi:

<https://jurnal.untan.ac.id/index.php/jepin/article/view/93221>



Reflection

Penelitian ini memberikan pengalaman berharga dalam menerapkan Python untuk pengembangan model berbasis Natural Language Processing (NLP), khususnya dalam deteksi teks generatif AI menggunakan IndoBERT.

Melalui proses ini, saya belajar bagaimana melakukan fine-tuning model pre-trained secara efektif menggunakan Hugging Face Transformers, mengelola data teks dalam format yang sesuai, serta melakukan evaluasi menggunakan berbagai metrik performa.

Selain aspek teknis, proyek ini juga memperkuat kemampuan analitis saya dalam memahami hubungan antara hasil deteksi AI dengan sistem penilaian otomatis berbasis cosine similarity.

Integrasi keduanya menjadi tantangan menarik karena membutuhkan pemahaman menyeluruh terhadap pemrosesan teks, perhitungan matematis, serta penerapan logika penyesuaian skor dalam Python.

Pengalaman ini mengajarkan pentingnya eksperimen terukur, dokumentasi proses, dan evaluasi berulang dalam pengembangan model AI.

Secara keseluruhan, proyek ini tidak hanya memperkuat kemampuan saya dalam Python dan NLP, tetapi juga menumbuhkan mindset ilmiah dan profesional dalam mendesain solusi AI yang berdampak nyata.



Thank You



Oleh: Pitriani



Email: pitripitriani173@gmail.com



Web-Portfolio: <https://ppitria.github.io>

